李智诚

手机：(+86) 18621669483 | 邮箱：zhichenglee97@gmail.com | 主页：zhicheng0326 | 领英：Zhicheng Lee

教育背景

清华大学，计算机科学与技术系，硕士 2023.09 - 2025.06

KEG 实验室，导师：李涓子教授，中国政府奖学金，GPA：3.80 / 4.00

上海交通大学，自动化，本科 2017.09 - 2021.06

上海市政府三等奖学金，GPA：3.44 / 4.3，百分制：83.73

核心能力

- **Agentic RAG**：围绕 GLM-4-9B 开展 Agentic RAG 研究，覆盖工具调用与多步推理轨迹构建、监督微调（SFT）、评测及消融；硕士期间产出 2 篇共同一作论文（IJCNN、CIKM Demo）。
- **Agent Harness**：具备 Coding Agent、多 Agent 编排、上下文隔离及真实执行反馈闭环的设计与开发经验；熟悉 Claude Agent SDK、pi、Skills、Hooks 与 MCP 等 Agent 框架及工具机制。
- **评测与实验分析**：熟悉多跳问答 Benchmark 评测、LLM-as-a-Judge、Bad Case 分析及训练数据有效性验证；能够结合模型推理轨迹、工具执行反馈与消融实验分析 Agent 行为及效果。

工作经历

智谱 AI，大模型 Agent 算法 2025.08 - 至今

- 负责面向企业的 Agent 系统的架构设计与核心开发，围绕智能投研、Coding Agent 等真实业务场景，推动 Agent 能力建设与项目交付。

智谱 AI，AI 院，大模型算法（实习） 2024.07 - 2025.05

- 围绕大模型多步推理、工具调用与检索增强开展 Agentic RAG 研究；构造推理增强训练数据进行 SFT，在多跳复杂问答任务中引入反思与多次检索，形成共同一作论文 ReaRAG 发表于 IJCNN 2026。

Wise AI Malaysia，AI 工程师 2021.11 - 2023.08

- 主导基于 ResNet 的模型训练，覆盖数据构造与评测，通过第三方测试，满足 ISO-30107 Level 1 标准。

算法研究

ReaRAG - 面向多跳推理与工具调用的大模型微调 2024.07 - 2025.05

共同第一作者 | 负责训练数据构建、SFT 与模型评测

- **Agent 轨迹数据构建**：基于 MuSiQue、HotpotQA、NQ 等问答数据，使用 QwQ-32B-Preview 合成 Thought/Action/Observation 交替的多轮推理与检索轨迹，通过最终答案正确性筛选，构建约 **2 万条**多步工具调用训练数据。
- **SFT**：基于 GLM-4-9B 混合微调多步检索轨迹与通用指令数据；通过 Observation Loss Masking，将监督目标聚焦于 Thought/Action，使模型学习基于外部检索反馈的多步推理与工具调用决策。
- **评测与消融**：构建 Long-context vs. RAG 对比评测框架，将测试上下文扩展至 50k+ tokens；在 6 项复杂多跳问答评测集上使用 LLM-as-a-Judge 评估，平均准确率达 48.5%，较对照方法**提升 3.8pp**；通过消融实验验证训练收益（48.5% vs. 40.5%），并分析检索轮次与失败案例。

Agent & Harness 项目经历

Venture Buddy（VC 智能投研 Harness） 2026.07 - 2026.10

项目主导 | 负责垂直领域 Agent Harness、专家知识建模与研究策略自动迭代探索

- **垂直领域 Agent Harness**：基于 Claude Agent SDK，组合 Agents、Skills、Hooks 与 MCP 工具，构建面向投研任务的 Agent 执行框架，支持多 Agent 协作、工具调用及结构化研究成果生成。
- **专家知识驱动的 Agent 设计**：与 VC 投研专家合作，将 PEST 分析、产业机会识别、证据校验及跟踪决策等研究方法抽象为可复用的 Skills / Commands；通过多个专用 Subagents 协同执行，生成包含证据引用与研究推导过程的结构化行业扫描报告。
- **Self-improving Harness 探索**：设计 Builder-Runner-Reviewer 双层迭代架构，解耦任务执行与研究方法优化；结合结构化执行记录、证据矩阵及 LLM-as-a-Judge 探索研究策略自动迭代，并针对开放式任务评估信号不可靠的问题，调整为专家驱动的 Skills 优化方案。

某车企 ASPICE Coding Agent（车机单元测试生成） 2026.03 - 2026.04

项目主导 | 基于 pi 扩展多 Agent 编排与真实构建环境的反馈闭环

- **Coding Agent 架构**：基于 pi 实现多 Agent 任务编排，通过 Orchestrator 多角色调度代码 Explorer、Writer、Reviewer 子 Agent；通过 CLI / Skills 赋予 Agent 代码构建、测试执行及覆盖率检查能力。
- **Feedback Loop**：将编译错误、测试失败及覆盖率结果接入 Agent Loop，驱动测试代码的自动修复与重新验证，形成基于真实执行反馈的持续优化闭环。
- **上下文隔离**：对 Writer / Reviewer 进行上下文隔离，降低生成过程对评审的干扰；将多 Agent 编排及执行能力封装为可复用的 pi Extension，并应用于三个场景。
- **结果**：在车机端 Kotlin 业务模块中验证自动化单元测试生成能力，行覆盖率由 **28.0% 提升至 86.8%**，分支覆盖率由 **22.3% 提升至 71.3%**；完成客户阶段一验收。

某车企座舱娱乐 AI 萌宠视频生成 2025.09 - 2025.12

- **多模态 Agent Workflow**：构建 Image-to-Video 异步生成流程，基于 Redis、PostgreSQL、Worker 和对象存储实现多模型路由、任务调度及状态管理，集成 VLM 进行生成质量审核，完成客户 POC 验收。

学术论文

ReaRAG: Knowledge-guided Reasoning Enhances Factuality of Large Reasoning Models with Iterative Retrieval Augmented Generation
Jinxin Liu*, **Zhicheng Lee***, Shulin Cao, Jiajie Zhang, Weichuan Liu, Xiaoyin Che, Lei Hou, Juanzi Li
International Joint Conference on Neural Networks (IJCNN), 2026

AtomR: Atomic Operator-Empowered Large Language Models for Heterogeneous Knowledge Reasoning
Amy Xin, Jinxin Liu, Zijun Yao, **Zhicheng Lee**, Shulin Cao, Lei Hou, Juanzi Li
31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD), Vol. 2, 2025

DiaKoP: Dialogue-based Knowledge-oriented Programming for Neural-symbolic Knowledge Base Question Answering
Zhicheng Lee*, Zhidian Huang*, Zijun Yao, Jinxin Liu, Amy Xin, Lei Hou, Juanzi Li
Conference on Information and Knowledge Management (CIKM demo), 2024

Deep Semi-Supervised Learning via Dynamic Anchor Graph Embedding Learning
Zihao Wang, Enmei Tu, **Zhicheng Lee**
International Joint Conference on Neural Networks (IJCNN), 2021